DERİN ÖĞRENME • DENEYSEL ÇALIŞMA

S&P 500 Yön Tahmini: Derin Öğrenme Yaklaşımı

MIT 6.S191 Prensipleriyle Feedforward Neural Network Uygulaması

Binary Classification | TensorFlow / Keras | T+5 Gün Yön Tahmini | 9 Finansal Özellik | Dense + Dropout

PROBLEM ÖZETİ

Gürültülü finansal zaman serilerinden S&P 500'ün T+5 günlük yön hareketini (yükseliş / düşüş) tahmin eden bir ileri beslemeli sinir ağı — temel MIT 6.S191 derin öğrenme ilkeleri üzerine inşa edilmiştir.

Introduction to Deep Learning • Feedforward Dense Model

Problem Tanımı

Finansal zaman serilerinde sınıflandırma olarak yön tahmini

Finansal piyasalar, düşük sinyal-gürültü oranına (signal-to-noise) sahip karmaşık sistemlerdir. Fiyat hareketleri; makro haberler, likidite şokları, sektör rotasyonu ve sayısız psikolojik etmenin süperpozisyonudur.

Amacımız bu gürültülü verinin içinden öğrenilebilir bir yapı çıkarmak: T+5 gün sonraki kapanış fiyatının bugünkü fiyatın üzerine çıkıp çıkmayacağını tahmin eden bir ikili sınıflandırıcı (Binary Classification).

HEDEF DEĞİŞKEN

Hedef = 1 if Fiyat(T+5) > Fiyat(T)
0 aksi halde

Her örneklem için 5 iş günü ileri kaydırılmış kapanış fiyatı, bugünkü kapanıştan yüksekse sınıf 1 (yükseliş), aksi halde sınıf 0 (düşüş).

VERİ SETİ

- ~257.000 satır günlük fiyat verisi
- S&P 500 sektör ETF'leri
- Makro olay pencereleri etrafında

NEDEN ZOR?

Rastgele tahmin tabanı ~%50'dir; her 1 puanlık gerçek iyileşme, ticari uygulamada önemlidir.

Volatilite rejim değişiklikleri, modelin genellemesini (generalization) sürekli tehdit eder.

Teknik Temel

MIT 6.S191 Ders 1'den Dense katmana uzanan zincir

1) Perceptron — atomik birim

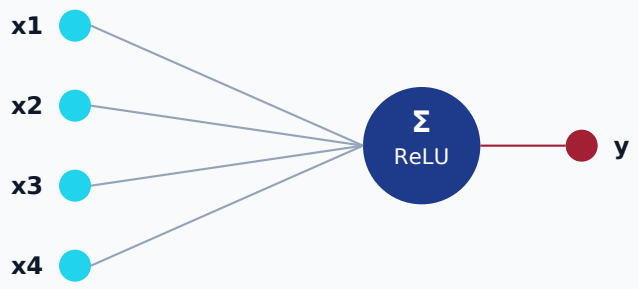

2) Matematiksel ifade

$$y = \sigma(W \cdot x + b)$$

- W — ağırlık matrisi (öğrenilen)
- b — sapma terimi (bias)
- σ — aktivasyon: ReLU / Sigmoid
- x — giriş özellik vektörü (9 boyut)

3) Dense (tam-bağlı) katman

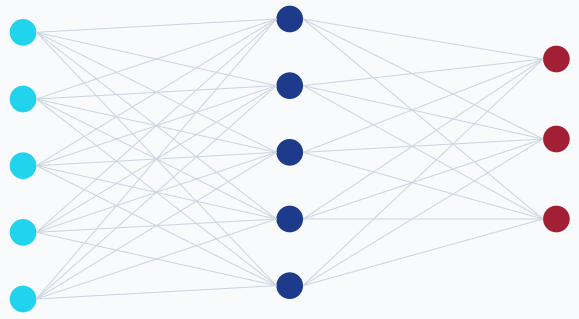

Perceptron, ağırlıklı girdileri toplayıp aktivasyona sokan tek nörondur. Birden fazla perceptron'u paralel dizerseniz tam-bağlı Dense katmanı, Dense katmanları peş peşe eklediğinizde ise ileri beslemeli (feedforward) derin sinir ağını elde edersiniz.

NEDEN FEEDFORWARD?

Girdimiz sabit boyutta, satır başına tek bir örneklem — Dense mimari bu tür tabular problemde ilk denenecek güçlü temel modeldir (baseline).

Veri ve Özellik Mühendisliği

Finansal göstergelerden öğrenilebilir sinyal üretimi

9 Girdi Özelliği → Dense(64) katmanına

`Log_Getiri`	Fiyatın logaritmik getirisi
`Volatilite_10g`	10 günlük oynaklık ölçüsü
`Volatilite_30g`	30 günlük oynaklık ölçüsü
`RSI_14`	Göreceli Güç Endeksi (momentum)
`MACD_12_26_9`	Hareketli ortalama yakınsama/ıraksama
`MACDh_12_26_9`	MACD histogram bileşeni
`MACDs_12_26_9`	MACD sinyal çizgisi
`BBL_20_2.0`	Bollinger alt bandı (20g, 2σ)
`BBU_20_2.0`	Bollinger üst bandı (20g, 2σ)

1) StandardScaler — Ölçeklendirme

Her özellik sıfır ortalama ve birim varyansa çekilir (z-score).
Gradient tabanlı eğitimde yakınsama hızını ve kararlılığı artırır.
fit() yalnızca eğitim setine uygulanır; test için sadece transform().

2) shuffle = False — Zaman Serisi Bütünlüğü

Train/Test ayrımında veri karıştırılmaz.
Geçmiş ile eğitilir, gelecek ile test edilir.
Karıştırma, modele gelecekteki bilgiyi sızdırır (data leakage).

3) Leakage-safe pipeline

Ölçeklendirme parametreleri yalnızca train'den hesaplanır.
Bu, geleceği bugüne taşımayı önler — realistik metrikler üretir.

Model Mimarisi

Dense(64) → Dropout → Dense(32) → Dropout → Sigmoid

İleri Besleme (Forward Pass)

Girdi vektörü → katmanlar arası tam-bağlı dönüşüm → Sigmoid olasılık

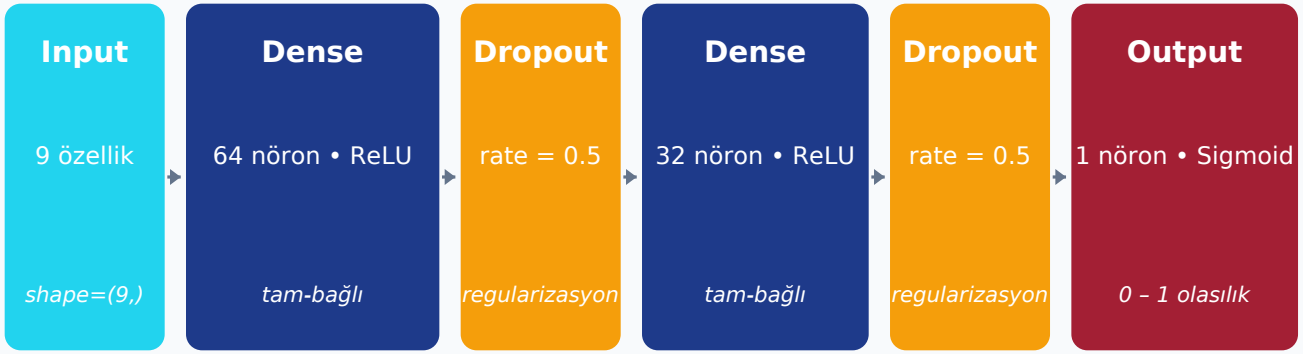

ReLU • gizli katmanlarda

Sıfırın altını kırpar, türevlenebilir, seyrek aktivasyon sağlar.
Vanishing gradient problemini büyük ölçüde azaltır.

Sigmoid • çıkış katmanında

Gerçek sayıyı (0, 1) aralığına sıkıştırır.
Doğrudan ikili sınıflandırma olasılığı olarak yorumlanır.

Dropout (%50) + Early Stopping

Eğitimde rastgele %50 nöron kapatılır — overfitting'e karşı.
Val-loss 10 epoch iyileşmezse eğitim durur; en iyi ağırlıklar geri yüklenir.

Eğitim Süreci ve Kayıp Analizi

Binary Crossentropy kaybının zaman içindeki davranışı

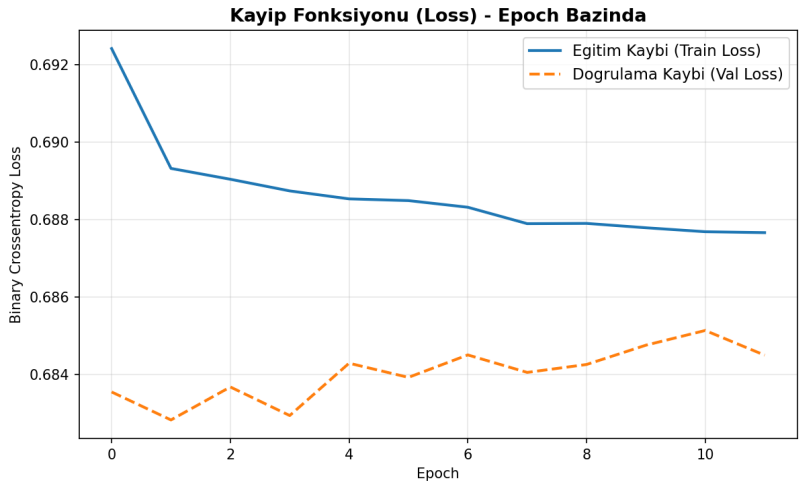

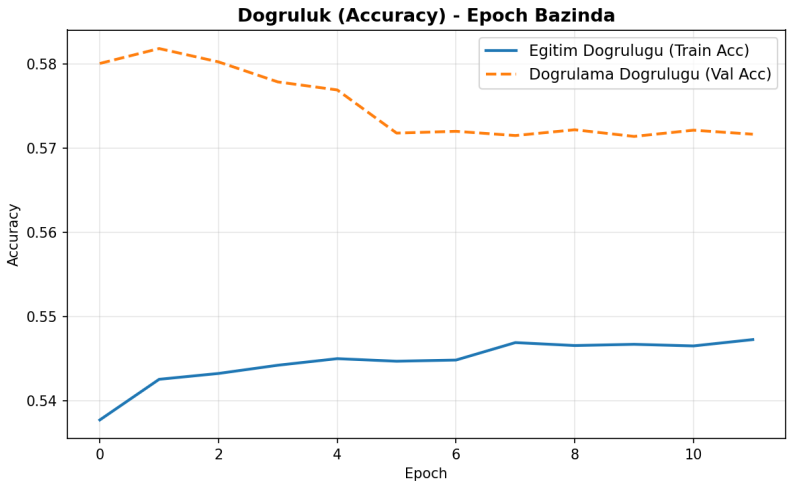

BINARY CROSSENTROPY

$$L = -[y \cdot \log(y) + (1-y) \cdot \log(1-y)]$$

İkili sınıflandırmanın standart kayıp fonksiyonu — olasılıkların doğruluğunu cezalandırır.

Eğitim eğrisi ne anlatıyor?

Train ve validation eğrileri benzer seviyede — büyük bir overfitting gözlenmiyor. Adam optimizer ilk epoch'larda hızlı iner, sonra düzleşir.

Overfitting önlemleri

Dropout(0.5) — her geçişte farklı alt-ağ eğitilir.
Early Stopping (patience=10) — en iyi val-loss'a döner.
Mini-batch = 64 ile gürültülü gradient.

Not: Finansal veride kayıp eğrisinin düzleşmesi, modelin mevcut özelliklerle öğrenebileceği sinyalin tavanına yaklaştığına işaret eder.

Performans Değerlendirmesi I

Karışıklık Matrisi (Confusion Matrix) ve ROC / AUC

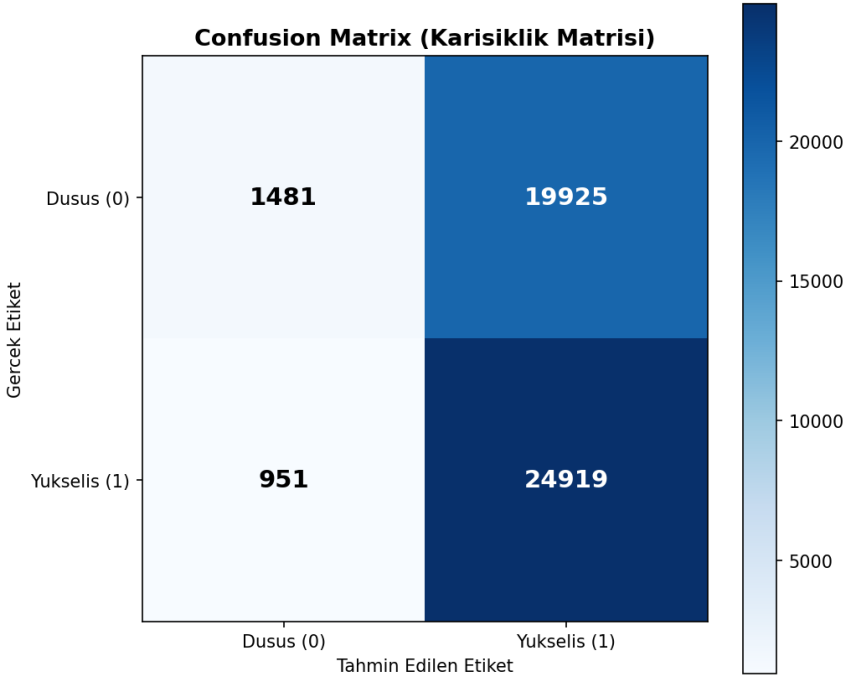

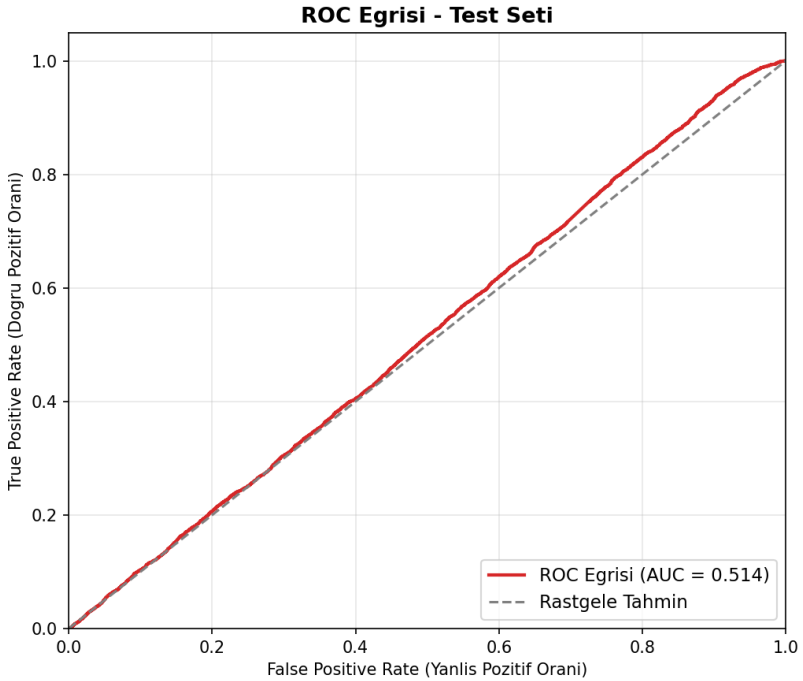

AUC DEĞERİ

0.514

AUC nasıl okunur?

AUC = 0.5 → rastgele tahmin.
AUC = 1.0 → mükemmel ayrıştırma.
Modelimiz 0.514 ile rastgeleliğin az üzerinde — sinyal zayıf, ancak sıfır değil.

Neden yükseliş sınıfına meyilli?

Eğitim veri setinde sınıf dengesi hafif yükseliş yönlüdür. class_weight kullanılmadığından model çoğunluğa kayar.

Matris: "1 (yükseliş)" tahminleri baskın — dengesiz dağılım ve 0.50 eşiğinin birleşik etkisi.
ROC 45° köşegene yakın: mevcut 9 özellik ile elde edilen ayrıştırma kapasitesi sınırlı.

Performans Değerlendirmesi II

Sigmoid olasılık çıktısının dağılımı

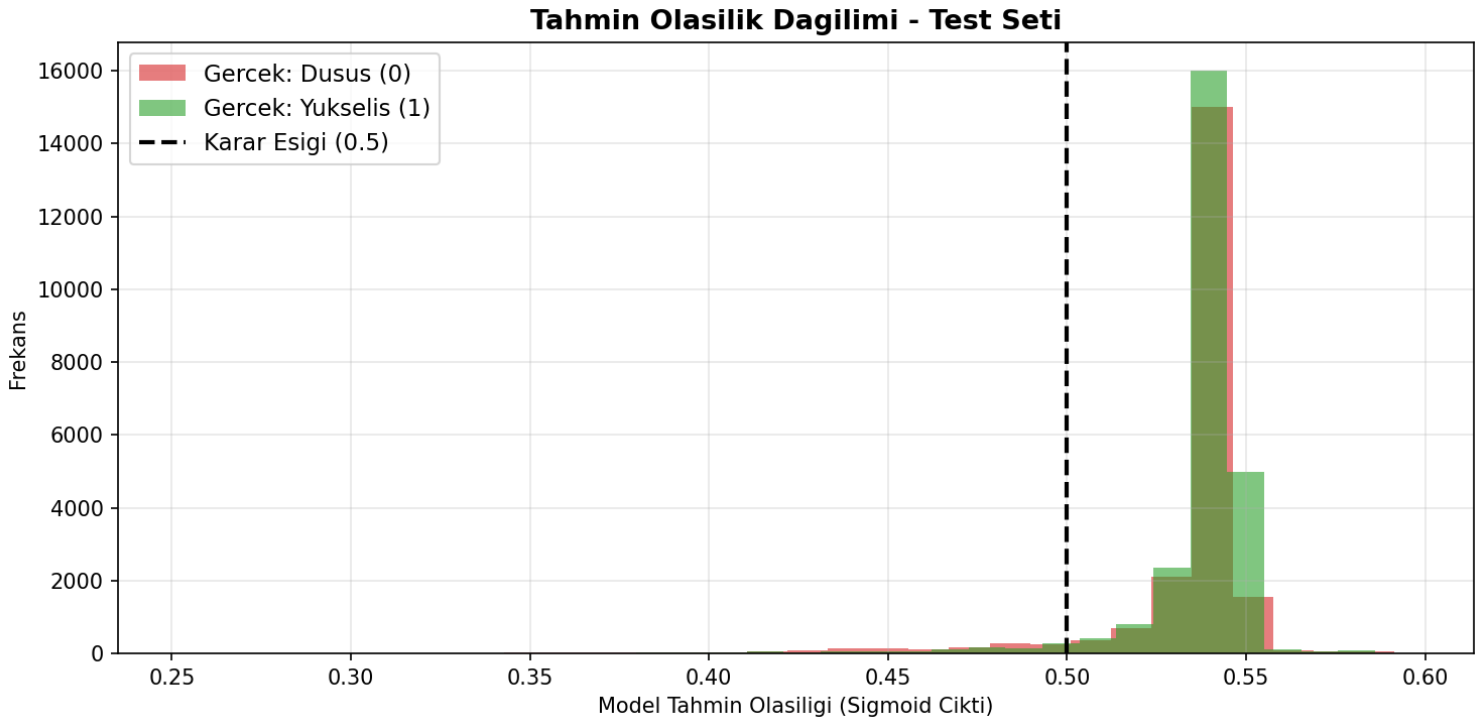

Dağılım ince bir çan eğrisi — yüksek bilgi içerikli sınıflandırıcıdan beklenen iki-kutuplu U şekli yerine.

Ne görüyoruz?

Sigmoid çıktıları 0.50 – 0.55 aralığında yoğunlaşıyor.
Model uç güven seviyelerinde (0.05 veya 0.95) tahmin üretmiyor.

Finansal yorum

Bu sıkışma, finansal verinin düşük sinyal-gürültü oranının yansımasıdır.
Model hafif bir yükseliş sinyali buluyor, ama bundan emin değil — güven dağılımı dar.

Pratik sonuç

Eşiği 0.50 yerine 0.55'e çekmek → daha az fakat daha yüksek kaliteli tahminler.
Karar eşiği portföy stratejisine göre ayarlanmalı.

SONUÇ VE İLERİ ADIMLAR

Bu sadece başlangıç — derin öğrenme yolculuğunun ilk adımı

Mevcut Durum

- AUC ≈ 0.514, test doğruluğu ~%51
- Feedforward Dense modeli rastgeleliğin sınırında
- 9 özellik ile günlük bağımsız örneklemler kullanıldı

Öğrendiklerimiz

- Zaman serisi için shuffle=False ve leakage-safe scaling kritik
- Dropout + EarlyStopping overfitting'i frenledi
- Sigmoid dağılımının sıkışması sinyal sınırını gösteriyor

Sonraki Adım

- RNN / LSTM ile sekans modelleme
- Kayan pencere (sliding window) ile 3D girdi
- Attention / Transformer tabanlı mimariler

MIT 6.S191 BAĞLANTISI

Ders 1'de temellendirilen Perceptron → Dense → Multi-layer yapı, burada gerçek bir finansal problemin sert sınırlarıyla buluştu. Ders 2'nin konusu Recurrent Neural Networks (RNN/LSTM), zamansal bağımlılıkları daha iyi yakalayarak bu tabanı aşmamızı sağlayacak.