

BÖLÜM 1

Giriş ve Problem Tanımı

S&P 500 Nedir?

S&P 500, ABD'nin en büyük 500 halka açık şirketinin hisse performansını tek bir rakamda toplayan bir endekstir. Apple, Microsoft, JPMorgan gibi şirketler bu sepetin içindedir. Endeksin yönü, küresel ekonominin genel sağlığını yansıtan en önemli göstergelerden biridir.

Yönünü Tahmin Etmek Neden Zor?

Finansal piyasalar, teknik tabirle **düşük sinyal-gürültü oranına (low signal-to-noise ratio)** sahip sistemlerdir. Bu ne demek? Fiyat hareketleri iki tür bilgiyi içerir:

Sinyal: Fiyatı gerçekten etkileyen ekonomik nedenler (şirket kârları, faiz kararları, arz-talep dengesi).

Gürültü: Milyonlarca yatırımcının psikolojik tepkileri, panik satışları, geçici haber dalgaları.

Finansal verilerde gürültünün oranı sinyalden çok yüksektir. Bu yüzden rastgele tahmin bile yaklaşık %50 doğruluk verir — her 1 puanlık gerçek iyileşme, yatırım stratejisinde ciddi bir avantaj sayılır.

Neden Derin Öğrenme?

Geleneksel istatistiksel yöntemler (doğrusal regresyon gibi), verinin belli varsayımlara (örneğin değişkenler arasında doğrusal ilişki olması) uyduğunu kabul eder. Ancak finansal piyasalar **doğrusal olmayan (non-linear)** ve **durağan olmayan (non-stationary)** yapıdadır; yani ilişkiler zamanla değişir ve basit kalıplara uymaz.

Derin öğrenme modelleri, bu karmaşık yapıyı çözmek için iki önemli avantaj sunar:

Verinin altında yatan kalıplar hakkında **önceden varsayım yapmazlar**; doğrudan veriden öğrenirler.

Milyonlarca ince ayar parametresi sayesinde, **doğrusal olmayan örüntüleri** (nonlinear patterns) yakalayabilirler.

Bu rapor, aynı problemi iki farklı derin öğrenme yaklaşımıyla ele alan iki çalışmayı kıyaslıyor: Benim **Feedforward (Dense) sinir ağı**mı ve Samuel Edet'in **Tekrarlayan Sinir Ağları (RNN / LSTM / GRU)** tabanlı akademik çalışmasını. Amaç; her iki yaklaşımın mimari, veri işleme ve sonuç boyutlarında nerede buluşup nerede ayrıldığını net bir şekilde göstermektir.

BÖLÜM 2

İki Farklı Yaklaşım: Modellerin Kıyası

Benim Modelim: Feedforward (İleri Beslemeli) Sinir Ağı

Feedforward Neural Network en temel derin öğrenme mimarisidir. Bilgi, girdiden çıktıya **tek yönde** akar. Model, kendisine verilen bir satır veriyi (örneğin bugünkü 9 finansal göstergesi) işler ve bir tahmin üretir. Ardından bir sonraki satıra geçer — **önceki satırı tamamen unutmuştur**. Hafızası yoktur.

Mimari: Giriş (9 özellik) → Dense(64) → Dropout → Dense(32) → Dropout → Sigmoid

Makalenin Modeli: RNN ve LSTM (Hafızalı Ağlar)

Samuel Edet'in makalesi ise **Tekrarlayan Sinir Ağlarını (Recurrent Neural Networks — RNN)** kullanıyor. Bu ağlar, işledikleri her bilgiyi bir **iç hafızada (hidden state)** saklar ve bir sonraki adımda hem yeni bilgiyi hem de geçmişin özetini birlikte değerlendirir. Böylece zaman içinde biriken örüntüleri yakalayabilirler.

Makalede üç RNN türü inceleniyor:


Simple RNN: En temel hafızalı ağ. Uzun geçmişte eski bilgilerin silikleşmesi ("vanishing gradient") sorunu yaşar.

LSTM (Long Short-Term Memory): Üç kapı (giriş, unutma, çıkış) sayesinde neyi hatırlayıp neyi unutacağına karar verir. Uzun vadeli bağımlılıkları LSTM çok daha iyi yakalar.

GRU (Gated Recurrent Unit): LSTM'in basitleştirilmiş versiyonu; daha az parametreyle benzer iş görür, daha hızlı eğitilir.

METEOROLOG ANALOJİSİ

Feedforward, yarınki havayı tahmin ederken *yalnızca bugünün gazetesine* bakan bir meteorologdur. Dün ne olmuş, hafta boyunca basınç nasıl değişmiş — hiçbirini hatırlamaz. **RNN / LSTM** ise *son bir haftanın tüm gazete arşivini* zihninde tutan bir meteorologdur. Karar verirken hem bugünün verilerini hem de geçmişteki trendleri birlikte değerlendirir.



Özellik	Feedforward	RNN / LSTM / GRU (Makale)
Hafıza	Yok	Var
Girdi yapısı	2D: (Örneklem, Özellik)	3D: (Örneklem, Zaman Adımı, Özellik)
Zaman serisi uygunluğu	Düşük	Yüksek

Veri ve Eğitim Stratejisi Kıyaslaması

Veri Setleri: İki Farklı Felsefe

Her iki projede de amaç aynı olmasına rağmen, veriye yaklaşım tamamen farklıdır.

Projem – 9 Teknik Gösterge + Büyük Veri:

Yaklaşık **257.000 satırlık** S&P 500 sektör ETF verisi kullandım. Ham fiyat yerine, piyasanın içindeki bilgiyi farklı açılardan özetleyen 9 teknik gösterge ürettim:

- **Log getiri:** Günlük yüzde değişimin standardize edilmiş hali.
- **Volatilite (10 ve 30 günlük):** Fiyatın ne kadar oynadığını ölçer.
- **RSI (Göreceli Güç Endeksi):** Aşırı alım/satım durumunu gösterir.
- **MACD ve bileşenleri:** Trendin yönünü ve gücünü ifade eder.
- **Bollinger Bantları:** Fiyatın istatistiksel olarak "normal" aralığının sınırlarıdır.

Yaklaşımım, **piyasanın kendi içindeki teknik dinamiklerden** bilgi çıkarmak üzerine kurulu.

Makalenin Projesi – 14 Makro Değişken → 3 Değişken:

Samuel Edet, S&P 500'ü dışarıdan etkileyen 14 değişken topluyor: Önceki üç günün S&P 500 kapanışları, 6 ülke borsa endeksi (Hong Kong, Almanya, İngiltere, Fransa, NASDAQ, Dow Jones) ve 5 büyük ABD şirketinin hissesi (Exxon, P&G, GE, Microsoft, Johnson & Johnson).

Ancak 14 değişkenin hepsini kullanmak doğru değil: Birbirleriyle çok benzer hareket edenler var. Örneğin Microsoft ile GE hisseleri neredeyse paralel dalgalanır. Makale, **korelasyon eşiği 0.5** uygulayarak aşırı benzer olanları eler ve 14 değişkenden geriye sadece **3 tanesini** bırakır:

- **SPYt-1** (önceki günün S&P 500 kapanışı)
- **JNJ** (Johnson & Johnson hissesi)
- **IXIC** (NASDAQ endeksi)

Projemde kullandığım önlem: `train_test_split(..., shuffle=False)` — Bu tek parametre, veriyi rastgele karıştırmak yerine zaman sırasına göre ilk %80'i eğitim, son %20'yi test olarak ayırır. Böylece model geçmişle eğitilir, gelecekle test edilir — aynen gerçek hayattaki gibi.

Overfitting'i Önlemek: Dropout

Overfitting (aşırı öğrenme), modelin eğitim verisini ezberleyip yeni verilere genelleme yapamaması durumudur.

Projemde kullandığım önlem: `Dropout(0.5)` — Eğitim sırasında her adımda nöronların %50'sini rastgele "kapatır". Böylece model tek bir nörona aşırı bağımlı hale gelemmez; bilgiyi ağ boyunca dağıtmak zorunda kalır, genelleme kapasitesi artar.

BÖLÜM 4

Çarpıcı Sonuçlar: Başarı Uçurumu

İki yaklaşımın sonuçları arasındaki fark, derin öğrenmede **model seçiminin ne kadar kritik olduğunu** çok net gösteriyor.

BENİM MODELİM (FEEDFORWARD)

%55.79

Test Doğruluğu · AUC: 0.514

MAKALENİN MODELİ (SIMPLE RNN)

%75.00

LSTM: %74 · GRU: %74

Zamansal Hafıza Eksikliği

Sınıf dengesizliğini düzeltsek bile, %55'ten %75'e sıçramak mümkün olmaz. Çünkü asıl **yeteneğinden** kaynaklanıyor:

fark, kullanılan modelin **yapısal**

Benim modelim bir günü kendi başına değerlendiriyor: "Bugün RSI 45, volatilite düşük. Bu durumda ne olur?" **RNN/LSTM** ise şunu diyor: "Son 5 günde RSI 30'dan 45'e yükseldi, volatilite yavaşça azalıyor, MACD güç kazanıyor. Bu *dizilim* bir yükseliş habercisi." Finansal zaman serilerinde bilginin büyük kısmı, tek bir anda değil, **ardışık değişim dizilerinde** saklıdır. Feedforward bu dizilimi göremez; RNN ve LSTM tam olarak bunun için tasarlanmıştır.

Yani kısaca: **%20'lik devasa başarı farkının asıl kaynağı, hafızasızlıktır.** Finansal zaman serisine hafızasız bir modelle yaklaşmak, bir futbol maçını tek bir fotoğraf karesine bakarak yorumlamaya benzer — birçok önemli bilgi görünmez kalır.

- ✓ **Leakage-safe pipeline:** **shuffle=False** ve yalnızca eğitim setine uygulanan **StandardScaler** ile zaman sırası ve veri bütünlüğü korundu. Model geçmişle eğitildi, gelecekle test edildi — gerçekçi bir değerlendirme elde edildi.
- ✓ **Overfitting önlemleri:** Dropout (0.5) ve Early Stopping (patience=10) birlikte kullanıldı; model sadece 14 epoch'ta durdu ve ezber yerine genelleme yaptı.
- ✓ **Zengin özellik seti:** Ham fiyat yerine 9 finansal gösterge (volatilite, RSI, MACD, Bollinger vb.) ile piyasanın farklı yönleri modele sunuldu.
- ✓ **Büyük veri hacmi:** 257.000 satırlık örneklem, sonuçların istatistiksel olarak güvenilir olmasını sağladı.

Projede eksik kalanlar:

- ✗ **Hafızasız model mimarisi:** Feedforward, zaman serisinin ardışık yapısını yakalayamıyor. Bu, %20'lik başarı farkının asıl nedeni.
- ✗ **Sınıf dengesizliği yönetilmedi:** **class_weight** kullanılmadığı için model çoğunluk sınıfına (yükseliş) yaslanmaya meyilli hale geldi.
- ✗ **Sistemik mimari seçimi eksikti:** Nöron ve epoch sayıları tek bir konfigürasyonda sabitlendi; makaledeki gibi deneysel tasarımı (DoE) optimize edilmedi.